



AI 每日全景报告

AI Daily Panorama Report · Bilingual Edition



2026年8月15日 (周六)



覆盖时段: 8月15日 00:00 ~ 8月15日 24:00 北京时间



共 32 条 / 16 个溯源来源

数据来源: WebSearch 多源检索 (AI 资讯聚合 + 官方博客 + 外资行研报) · 每条均附原文链接



国内进展 5



海外动态 7



行业与资本 7



大V观点 2



技术进展 3



研报论文 5



当日要闻表

/ Day-at-a-glance

8 条

收起

时间	事件	影响
8月15日 10:00	Google 发布 Gemini 3.7 Flash, 价格为前代一半	编码/智能体推理成本骤降, 价格战向推理层蔓延
8月15日 14:30	阿里开源 Qwen3.8 系列, 27B 版消费级显卡可跑	国产开源模型"集团军"成型, 端侧部署门槛再降
8月15日	智谱发布 GLM-5.3, 编程能力较前代提升约 50%	国产模型能力逼近前沿, 开源榜登顶在望
8月15日	Databricks 完成 50 亿美元融资, 估值 1900 亿美元	企业 Agent 基建估值锚定, 资本向基础设施集中
8月15日	SpaceX 以 600 亿美元全股票收购 Cursor	AI 编程赛道军备竞赛升级, 算力与代码智能体整合
8月15日	Anthropic 洽购以色列 Decart AI 约 60 亿美元	或为史上最大收购, 算力效率成战略资产
8月15日	欧盟 AI Act 透明度/水印条款正式执行 (8/2 生效)	全球 AI 监管进入落地期, 合成内容须机器可读水印

时间	事件	影响
8月15日	高盛：2026 美国 AI 投资近 6000 亿美元，约 GDP 2%	资本开支成为宏观经济变量，挤出效应有限但存在

阿里开源 Qwen3.8 系列：27B 版消费级显卡可跑，Qwen3.8-Max 达 2.4 万亿参数

EN: Alibaba open-sources Qwen3.8 — a 27B dense model (Apache 2.0, runs on consumer GPUs) plus a 2.4T-param Max flagship.

听松613 / 头条 AI 前沿日报 8月15日 14:30 开源模型

阿里巴巴正式开源 Qwen3.8，其中 27B 参数版本超越上代 Qwen3.7-Plus，采用 Apache 2.0 协议，消费级显卡即可运行；同步确认 Qwen3.8-Max 规模达 2.4 万亿参数。千问全球下载量已突破 30 亿次。国产大模型从“以价换量”转向“开源 + 超大参数”双轨并进。

EN — Two-track move: open-weight mid-size for the edge, trillion-param Max to contest the frontier; total Qwen downloads past 3 billion.

智谱发布 GLM-5.3：编程能力提升约 50%，Terminal Bench 3.0 开源第一

EN: Zhipu releases GLM-5.3 (743B params) — coding up ~50%, #1 open-source on Terminal Bench 3.0.

AI 日报 blog.aichanning.cn 8月15日 国产大模型

智谱 AI 发布 GLM-5.3，总参数 7430 亿，通过后训练 Scaling 大幅提升智能上界，编程能力较前代提升约 50%，在 Terminal Bench 3.0 等公开基准中拿下开源第一。完整权重将在两周内开源，API 同步上线，并面向政企提供离线部署版本。

EN — Post-training scaling lifts the intelligence ceiling; weights to be open-sourced within two weeks, with an offline enterprise edition.

小红书开源 dots3-note Preview：280B 总参 / 16B 激活，512K 上下文

EN: Xiaohongshu (RED) open-sources dots3-note Preview — 280B total / 16B active, 512K context, multimodal.

AI 日报 blog.aichanning.cn 8月15日 开源模型

小红书技术团队开源 dots3-note Preview，总参数 280B、激活 16B，支持 512K 上下文与多模态，定位长程 Agent 与复杂推理。低激活参数路线与同日 Qwen3.8、GLM-5.3 形成“中国开源周”的密集发布态势。

EN — Low-activation MoE for long-horizon agents; joins a密集 domestic open-source release wave on the same day.

DeepSeek V4 Pro 0813 正式版上线，API 大幅涨价；Harness 智能体框架开源

EN: DeepSeek ships V4 Pro 0813 GA (1.6T params) and open-sources DeepSeek Harness; API prices rise.

听松613 / 头条 AI 前沿日报 8月15日 Agent 框架

DeepSeek 发布 V4 Pro 0813 正式版，旗舰模型 **1.6 万亿参数**，DeepSWE 从 12.8 升至 62.7、CyberGym 从 52.7 升至 83.3；同步开源智能体执行框架 **DeepSeek Harness**（“一切皆插件”，GitHub 12 小时破 5 万星），被视为 Agent 领域的“安卓”时刻。API 最高涨价 11 倍，标志“低价红利”时代落幕。

EN — The “price-war” posture is reversed: rising API prices + an open agent framework signal a shift from commoditized inference to platform play.

Google Sheets canvas：自然语言把表格转成交互式迷你应用

EN: Google Sheets canvas turns natural-language prompts into interactive mini-apps, deepening Gemini into the office suite.

AI 日报 blog.aichanning.cn 8月15日 办公智能体

Google 推出 Sheets canvas，用自然语言即可把电子表格转成交互式迷你应用，Gemini 继续向办公套件深处钻。与 Gemini 3.7 Flash 的低价编码能力形成闭环——办公自动化从“函数公式”走向“对话即应用”。

EN — Office suites become app platforms via conversation; part of Google's deeper Gemini-ification of Workspace.

● 海外大模型与应用动态 / Global: Models & Products

7 条 ▾ 收起

Google 发布 Gemini 3.7 Flash：编码与智能体优化，价格减半

EN: Google launches Gemini 3.7 Flash for coding/agents at half the price of 3.6 Flash.

Pondero AI Daily Brief (8/15) 8月15日 10:00 前沿模型

Gemini 3.7 Flash 于 8月13日 抵达，Google 称其最强 Flash 级模型，主攻编码与智能体 workflow。定价 **\$0.75 / 百万输入、\$3.75 / 百万输出**，为 3.6 Flash 的一半（限时至 12/31），提供 **100 万 token 上下文**、单次最多 6.4 万输出 token。已在 Gemini API、Gemini Spark、AI Studio 上线。

EN — A 50% price cut on the Flash tier is the most immediate reason for teams to evaluate it for coding/agent workloads.

OpenAI × Cerebras 预览 GPT-5.6 Sol "Ultrafast": 速度最高 14 倍

EN: OpenAI + Cerebras preview GPT-5.6 Sol Ultrafast — up to 750 tokens/s, 14x Standard, no quality loss.

Cerebras 官方新闻稿 (8/13) 8月15日 持续发酵 推理加速

OpenAI 联合 Cerebras 推出 Ultrafast 服务层级，GPT-5.6 Sol 输出速度最高 **750 tokens/s**，为标准模式约 **14 倍**，且不降智。Humanity's Last Exam (2500 题) 仅 11 小时答完，Claude Fable 5 需 78 小时。架构核心是将权重常驻于晶圆级芯片 44GB 片上 SRAM，绕开 GPU 显存带宽瓶颈。早期客户含 Jane Street、Podium。

EN — Inference speed becomes a product tier; wafer-scale SRAM removes the memory-bandwidth bottleneck that constrains GPU serving.

OpenAI 接入 Google Drive 与 macOS 历史：ChatGPT 走向"环境上下文"

EN: OpenAI adds Google Drive to ChatGPT Library and macOS Computer History for ambient context.

Pondero AI Daily Brief (8/15) 8月15日 生态整合

8月14日 两项 ChatGPT 能力上线：① Google Drive 接入 ChatGPT Library，Plus/Pro/Business/Enterprise 用户可在对话内浏览、@ 引用并编辑 Docs/Sheets/Slides，文件不重新上传 OpenAI 服务器；② macOS Computer History，可选功能，让 ChatGPT 与 Codex 引用过往应用与网页活动以形成跨会话持久上下文（仅记录交互事件，排除隐私浏览）。

EN — Both target Pro/Business/Enterprise; the macOS feature records interaction events, not screenshots or audio.

xAI 发布 Grok 4.6：专注长程 Agent 与复杂 workflow

EN: xAI releases Grok 4.6 — long-horizon agents, coding, knowledge work; \$2/\$6 per M in/out tokens.

听松613 / 头条 AI 前沿日报 8月15日 前沿模型

xAI 发布 Grok 4.6 前沿模型，专注长程 Agent、编程、知识工作与交互式应用开发，在推理、工程、STEM 与 Agent 数据上扩展训练。API 定价 **\$2 / 百万输入**、**\$6 / 百万输出**，可通过 Grok Build、Cursor、OpenRouter、Vercel 多平台使用。

EN — Priced below frontier peers; available across multiple platforms including OpenRouter and Cursor.

微软发布 MAI-Thinking-1 推理模型：完全从零训练，不依赖蒸馏

EN: Microsoft ships MAI-Thinking-1 (35B active / ~1T total, sparse MoE), trained from scratch, no distillation.

听松613 / 头条 AI 前沿日报 8月15日 推理模型

微软 AI 团队发布 MAI-Thinking-1 推理模型 (**35B 活跃参数、约 1T 总参数**，稀疏 MoE)，完全从零训练、不依赖任何第三方模型蒸馏。AIME 2025 达 97.0%、AIME 2026 达 94.5%，SWE-Bench Pro 与 Claude Opus 4.6 持平，盲测优于 Claude Sonnet 4.6。标志大厂自研底座摆脱"蒸馏依赖"。

EN — From-scratch training avoids distillation; competitive with Opus 4.6 on agentic SWE benchmarks.

Google DeepMind 发布 AlphaEvolve：自进化算法打破多项数学纪录

EN: DeepMind's AlphaEvolve combines Gemini + evolutionary search; beats 56-year-old Strassen algorithm.

听松613 / 头条 AI 前沿日报 **8月15日** **科研自动化**

Google DeepMind 推出 AlphaEvolve，将 Gemini 大语言模型与进化优化结合，实现代码库级自主算法改进。已部署至 Google 数据中心回收 **0.7% 闲置算力**；解决 11 维空间"kissing number"问题（593 个球）；在 4×4 复数矩阵乘法上将乘法次数从 **49 降至 48**，超越诞生 56 年的 Strassen 算法。

EN — Beats a 56-year-old algorithm; deployed internally to reclaim idle compute in Google data centers.

Anthropic 推出 SynthID-Text 水印检测 API，遵守欧盟 AI Act

EN: Anthropic ships a SynthID-Text watermark detection API so third parties can detect Claude-generated text.

听松613 / Pondero (8/15) **8月15日** **合规/水印**

Anthropic 推出基于 SynthID 的水印检测 API，允许第三方开发者检测文本是否由 Claude 生成，以遵守欧盟 AI Act 的内容溯源要求；Google 同日允许用户关闭 Gemini 及 Flow 的可见"闪烁"水印，但不可见的 SynthID 数字水印与 C2PA 元数据仍保留。监管驱动的水印技术进入产品化阶段。

EN — Watermarking moves from research to product as the EU AI Act's transparency rules take effect (Aug 2).

行业动态与资本 / Industry & Capital

7 条 ▾ 收起

Databricks 完成 50 亿美元融资，估值 1900 亿美元

EN: Databricks raises \$5B at a \$190B valuation; ARR crosses \$7B as agent demand surges.

Pondero / Databricks 官方 (8/13) **8月15日** **融资**

Databricks 宣布完成 **50 亿美元** 战略融资，投后估值 **1900 亿美元**（2026 年第二次融资），Coatue 领投，Blackstone、MGX、T. Rowe Price、Sixth Street 参投。公司年化营收突破 **70 亿美元**、Q2 同比增长超 80%。资金投向三款企业 Agent 产品：Lakebase（Serverless Postgres）、Genie（AI 同事）、Unity AI Gateway（多云多模型治理与成本层）。

EN — The raise is a direct bet on enterprise-agent infrastructure; Lakehouse alone crossed \$1.5B ARR.

SpaceX 以 600 亿美元全股票收购 Cursor，xAI 同步推出 Grok Bot

EN: SpaceX acquires Cursor for \$60B all-stock; xAI launches always-on Grok Bot.

听松613 / 头条 AI 前沿日报 8月15日 并购

SpaceX 宣布以 **600 亿美元全股票**完成对 AI 编程公司 Cursor（母公司 Anysphere）的收购，创科技行业史上最大收购之一，Cursor 团队将接入 SpaceX 大规模 GPU 算力联合迭代 Grok 系列代码能力。xAI 同日推出常驻智能体 Grok Bot——关机后仍替用户干活，正式杀入"Vibe Coding"战场。

EN — A space + coding crossover; xAI's Grok Bot pushes the "always-on local agent" thesis further.

Anthropic 洽购以色列 Decart AI 约 60 亿美元

EN: Anthropic in talks to buy Decart AI for ~\$6B — its largest acquisition, for GPU efficiency.

Quadra Digital Daily AI Briefing 8月15日 并购

Anthropic 据报正洽谈收购以色列初创 Decart AI（实时生成视频与 GPU 效率软件），交易估值约 **60 亿美元**，较其 5 月 40 亿美元估值溢价约 50%。若落地将是 Anthropic 史上最大收购，目标是在 IPO 前从算力效率侧挤出更多性能——"效率即战略资产"逻辑延续。

EN — Compute efficiency becomes a strategic asset ahead of a widely anticipated IPO.

Manus 因中国监管令脱离 Meta，重获独立运营

EN: Manus to regain independence as Chinese regulators unwind Meta's \$2B acquisition.

Quadra Digital Daily AI Briefing 8月15日 监管/并购

AI 智能体创业公司 Manus 表示将"很快恢复独立运营"，此前中国监管机构以"外资投资中国 origin 技术"相关规则，责令 Meta 解除对其 **20 亿美元**收购。Meta 已切断 Manus 内部系统访问并禁止员工使用其工具。事件成为"中资 AI 技术出海并购"监管收紧的早期信号。

EN — An early signal of tightening scrutiny over foreign acquisition of Chinese-origin AI technology.

Dynatrace 以 9.15 亿美元收购 Arize，强化 AI 可观测性

EN: Dynatrace acquires Arize for \$915M, bolstering AI observability and LLM evaluation.

Pondero AI Daily Brief (8/15) 8月15日 并购

可观测性厂商 Dynatrace 以 **9.15 亿美元**收购 AI 评估平台 Arize。随着企业把 LLM/Agent 投入生产，模型监控、漂移检测与评测成为刚需，AI 可观测性赛道估值被重估。

EN — As agents hit production, observability/eval becomes a must-have layer, not a nice-to-have.

CME 拟推出 GPU 期货合约，AI 算力成可交易金融资产

EN: CME to launch GPU futures — compute becomes a tradable financial asset.

Quadra Digital Daily AI Briefing 8月15日 算力金融化

CME 集团计划推出 **GPU 期货合约**，使 AI 算力正式成为可交易金融资产。叠加英伟达联合六大金融机构动员超 5000 亿美元 AI 基建资本，算力正从“科技公司自建”走向“金融资产证券化”。

EN — Compute is being financialized: futures contracts + \$500B capital vehicles turn GPUs into an asset class.

Pony.ai 与 Uber 推 2000 辆 Robotaxi 欧洲扩张

EN: Pony.ai and Uber plan a 2,000-robotaxi European expansion.

Pondero AI Daily Brief (8/15) 8月15日 自动驾驶

Pony.ai（小马智行）与 Uber 宣布将部署 **2000 辆 Robotaxi** 推进欧洲市场扩张，AI 在实体出行场景的商业化落地加速，Robotaxi 从试点走向规模化运营。

EN — Robotaxi moves from pilots to scale as AV players partner with global ride-hailing networks.

KOL / 大V 观点 / Voices & Opinions

2 条 ▾ 收起

Anthropic 多智能体研究：45 个协调智能体在 2700 万 token 中发现 266 个漏洞

EN: Anthropic's multi-agent study — 45 coordinated agents over 27M tokens surfaced 266 vulnerabilities.

AI 日报 blog.aichanning.cn 8月15日 多智能体

Anthropic 披露多智能体系统研究：**45 个**协调智能体在 **2700 万 token** 运行中发现 **266 个漏洞**，系统性研究多智能体系统的风险与能力边界。能力跃升的同时，风险也呈系统性——为后续“智能体安全”议题埋下伏笔（次日 Anthropic 即发布专项风险报告）。

EN — Capability and risk scale together: 45 agents found 266 vulnerabilities, a preview of agentic-security concerns.

"Research Gold" 丑闻：标榜"100% 人类撰写"的医学研究服务，审稿人竟是 AI 虚构

EN: "Research Gold" scandal — a "100% human-written" medical research service used fictitious AI reviewers.

AI 日报 blog.aichanning.cn / Hacker News 8月15日 AI 滥用

标榜"100% 人类撰写、绝不使用 AI"的医学研究服务 Research Gold 被曝审稿人皆为 AI 虚构。这是 AI 滥用与“反 AI”叙事反噬的讽刺案例，也凸显内容溯源与“人类 authored”声明的可验证性问题。

EN — A cautionary tale on AI-washing and the verifiability of "human-authored" claims.

● 技术进展 / Engineering & Infrastructure

3 条 ▾ 收起

英伟达开源 Nemotron 3.5 Lightning: 300 亿参数, 单 GPU 可跑

EN: NVIDIA open-sources Nemotron 3.5 Lightning — 30B, runs on a single GPU; Nemotron 4 (1T) in the works.

听松613 / 头条 AI 前沿日报 8月15日 端侧模型

英伟达开源 Nemotron 3.5 Lightning, **300 亿参数**, 可在单 GPU 上运行, 专为常驻智能体设计。据悉英伟达正研发万亿参数的 Nemotron 4 系列, 对标全球前沿开源大模型。硬件厂商下场做开源权重, 意在用软件生态绑定自家算力。

EN — Hardware vendors shipping open weights to lock in their compute stack; Nemotron 4 (1T) reportedly next.

DeepSeek Harness 开源: 12 小时 GitHub 破 5 万星

EN: DeepSeek Harness — "everything is a plugin" agent framework, 50k stars in 12 hours.

听松613 / 头条 AI 前沿日报 8月15日 Agent 框架

DeepSeek 发布首个 Agent 产品 DeepSeek Harness, 采用"一切皆插件"的开源框架设计, 开发者可自由更换模型、工具、界面及核心循环组件。GitHub 公开仅 **12 小时即破 5 万星**, 涨势惊人, 被视为 Agent 领域的"安卓"时刻。

EN — A plugin-everything framework; the velocity (50k stars / 12h) signals developer hunger for open agent stacks.

Google Sheets canvas: 自然语言生成交互式迷你应用

EN: Sheets canvas turns prompts into interactive mini-apps — a step toward agentic office suites.

AI 日报 blog.aichanning.cn 8月15日 办公自动化

见"国内进展"卡片: Google 把自然语言转交互式应用的能力嵌入 Sheets, 办公套件向"对话即应用"演进, 是 Agent 落地的轻量级入口。

EN — Low-friction agent entry point inside the world's most-used spreadsheet.

● 优秀研报与论文提炼 / Research Digest · Sell-side

5 条 ▾ 收起

高盛：2026 美国 AI 投资近 6000 亿美元，约 GDP 的 2%

EN: Goldman Sachs — US AI investment ~\$600B in 2026 (~2% of GDP); crowding-out limited but real.

Goldman Sachs (8/10–8/11 研报, Jessica Rindels / David Mericle) 8月15日 引用 外资行宏观

高盛经济学家估计，美国 AI 投资 2026 年将达近 **6000 亿美元**（约占 GDP 2%），近期占企业固定投资超 10%、设备投资约 15%。报告认为对 GDP 的挤出效应**有限**：过去一年约挤出 500 亿美元其他支出（约 300 亿来自被替代的科技投资、100 亿+ 来自建筑、约 100 亿来自更高借贷成本），并估计 AI 投资仅给 2026 年 GDP 增长贡献 **0.1 个百分点**。

EN — Headline takeaway: both AI's GDP contribution and its crowding-out are "smaller than often thought" — ~\$50B incremental crowding-out in 2026.

摩根士丹利：上调超大规模厂商 2027/2028 资本开支至 1.2 万 / 1.4 万亿美元

EN: Morgan Stanley raises 2027/2028 hyperscaler capex to \$1.2T / \$1.4T; 2026 US big-tech capex revised \$433B→\$805B.

摩根士丹利 (Brian Nowak 团队) / 富途 8月15日 引用 外资行基建

大摩将全球五大超大规模云厂商（Meta、亚马逊、微软、谷歌、SpaceX）2027/2028 年资本开支预测显著上调至约 **1.2 万亿 / 1.4 万亿美元**；对 2026 年美国大型科技巨头资本开支预期从一年前的 4330 亿美元大幅上修至 **8050 亿美元**。AI 基建是当下最确定的宏观成长变量之一。

EN — Capex revisions keep climbing; the AI infrastructure super-cycle is being priced into multiples across the stack.

野村：三星 / SK 海力士目标价大幅上调，重估为"AI 基础设施成长资产"

EN: Nomura lifts Samsung (₩670k, +225%) and SK Hynix (₩4.7M, +255%) targets — re-rate memory as AI infra.

野村证券 / 富途 8月15日 引用 外资行半导体

野村将三星电子目标价由 59 万韩元上调至 **67 万韩元**（12 个月潜在涨幅 225%），SK 海力士由 400 万上调至 **470 万韩元**（潜在涨幅 255.5%）。逻辑：AI 训练/推理/数据中心扩张使存储需求持续高于供给；HBM 与通用存储进入共振式超级周期；两家约 6 倍预期市盈率显著低于台积电约 20 倍，未充分反映 ROE 上升。

EN — Memory re-rated from cyclical PC/phone stock to structural AI-infra asset; HBM + DRAM super-cycle thesis.

摩根士丹利《开放权重模型与三种未来情景》：提出"杰文斯悖论"

EN: Morgan Stanley — open-weight models may raise total compute demand via the Jevons Paradox.

摩根士丹利报告 (8/4) / 网易 8月15日 引用 外资行算力

大摩报告提出与传统担忧相反的观点：开放权重模型**不一定削弱**算力需求。更低的使用成本加快 AI 普及，形成典型"杰文斯悖论"——单次推理变便宜后，企业把 AI 用于更多任务，最终推高 token、算力、电力与基础设施的总需求。无论模型开放程度如何，英伟达等硬件厂商均有望受益。

EN — Cheaper inference → more tasks → more total compute; a bull case for NVIDIA regardless of open vs closed.

高盛 GS SUSTAIN：全球数据中心电力需求到 2030 年激增 170%

EN: Goldman Sachs GS SUSTAIN — global data-center power demand +170% by 2030; efficiency inflection near.


Goldman Sachs Research（8/6 报告） 8月15日 引用 外资行能源

高盛 8/6 发布的 GS SUSTAIN 报告将 2030 年全球数据中心电力需求增速预测从 117% 上调至 170%，累计增量超日本 2023 年全国用电量；八大超大规模厂商 2026 年 capex+R&D 合计将达 1.2 万亿美元。报告同时指出 AI 创新周期正从"评估与梦想期"转向"执行与效率期"，电网（变压器、开关柜、高压互联）成为比芯片更硬的瓶颈。

EN — Grid, not chips, is the binding near-term constraint; community opposition and labor shortages add risk.

超大规模厂商资本开支预测（万亿美元） — 摩根士丹利

来源：Morgan Stanley（Brian Nowak 团队）2026年8月研报。纵轴单位：万亿美元/年。



注：覆盖 Meta / 亚马逊 / 微软 / 谷歌 / SpaceX 五家超大规模厂商 capex（万亿美元/年）

今日总结 & 投资启示 / Takeaways

关键结论 / Key Takeaways

- ▶ **国产开源模型进入“集团军”阶段**：同日 Qwen3.8 (27B Apache 2.0 消费级可跑 + 2.4T Max)、GLM-5.3 (743B, 编程 +50%)、dots3-note (280B/16B 激活, 512K)、DeepSeek V4 Pro (1.6T) 密集发布, 中国开源模型在**规模、开放、生态**三线并进, 海外下载占比显著上升。
- ▶ **推理速度被产品化为独立层级**：OpenAI × Cerebras 的 GPT-5.6 Sol Ultrafast 将速度本身做成按性能分层收费的商业策略 (750 tokens/s、14 倍), 晶圆级 SRAM 绕开 GPU 显存带宽瓶颈。速度从“硬件 footnote”升级为“定价与包装杠杆”。
- ▶ **价格战从模型层烧到推理层**：Google Gemini 3.7 Flash 价格减半、DeepSeek 逆势涨价 11 倍、Grok 4.6 低价入局——“选一家焊死”被证伪, 按需路由 (编码走 Opus、批量走 DeepSeek/Kimi、端侧兜底本地开源) 成为主流策略。
- ▶ **资本向 AI 基础设施集中, 应用层腰部被绕开**：Databricks \$50 亿 / \$1900 亿估值、Anthropic 洽购 Decart \$60 亿、SpaceX 600 亿收购 Cursor、CME 拟推 GPU 期货。高盛估算 2026 美国 AI 投资近 \$6000 亿 (≈GDP 2%), 但挤出效应有限。
- ▶ **算力金融化开启**：英伟达联合六大金融机构动员超 5000 亿美元 AI 基建资本, CME 拟推 GPU 期货, 算力从“科技公司自建”走向“金融资产证券化”。需警惕“循环融资”与债务风险。
- ▶ **监管进入落地期**：欧盟 AI Act 透明度/水印条款 (8/2 生效) 正式执行, Anthropic 推出 SynthID-Text 检测 API, Google 保留不可见水印; Manus 因中国监管令脱离 Meta, 预示中资 AI 技术出海并购审查收紧。

 **叙事透镜**：本期一手信源占比高 (Cerebras、Databricks、Google、Anthropic 官方/新闻稿, 摩根士丹利/高盛/野村研报), 二手转述较少, 信息质量较高。可信度排序：官方新闻稿 > 外资行研报 (有量化模型支撑) > 聚合日报 > 大V解读。需打折的两处：① GPT-5.6 Sol Ultrafast 的 HLE/GDP-Val 对比为 Cerebras 自测 (vendor-run)；② 部分聚合日报对 8/15 与 8/16 事件存在口径交叉, 已按绝对日期归并。

EN — Bottom line. China's open-source models shipped as a coordinated wave (Qwen3.8, GLM-5.3, dots3-note, DeepSeek V4 Pro), narrowing the frontier gap on scale and openness. Inference speed became a product tier (OpenAI×Cerebras Ultrafast), while price competition spread from models to routing. Capital concentrated in infrastructure (Databricks \$190B, Cursor \$60B, GPU futures), and regulation moved from draft to enforcement (EU AI Act watermarks). Discount: Cerebras' self-run benchmarks, and some aggregator date-overlap.

重点公司/行业环比变化追踪 / Tracking

标的/行业	方向	变化	对比基准
阿里巴巴 / 通义千问	↑积极	开源 Qwen3.8 (27B 消费级可跑 + 2.4T Max) , 下载量破 30 亿; 集团军式开源压制闭源定价权	较上一报告期
智谱(Zhipu)	↑积极	GLM-5.3 发布, 编程 +50%、Terminal Bench 3.0 开源第一, 两周内开源权重	较上一报告期
DeepSeek	↑中性偏多	V4 Pro 1.6T 转正 + Harness 框架开源 (12h 破 5 万星) , 但 API 涨价 11 倍告别价格战	较上一报告期
Google	↑积极	Gemini 3.7 Flash 价格减半 (编码/智能体优化) ; Sheets canvas 嵌入办公; 保留不可见水印	较上一报告期
OpenAI	↑积极	GPT-5.6 Sol Ultrafast (Cerebras, 14 倍) ; 接入 Google Drive 与 macOS 历史; 环境上下文能力增强	较上一报告期
微软	↑积极	MAI-Thinking-1 从零训练推理模型 (35B 活跃/1T 总) , 摆脱蒸馏依赖	本期新增覆盖
xAI	↑积极	Grok 4.6 发布 (长程 Agent) ; Grok Bot 常驻智能体	本期新增覆盖
Databricks	↑积极	\$50 亿融资、估值 \$1900 亿, ARR 破 \$70 亿, 押注企业 Agent 三件套	本期新增覆盖
Anthropic	↑积极	洽购 Decart \$60 亿; SynthID-Text 检测 API 合规化	较上一报告期
英伟达(NVIDIA)	↑积极	Nemotron 3.5 Lightning 开源; 联合六大机构动员 \$5000 亿 AI 基建资本	较上一报告期
存储 / HBM (三星、SK海力士)	↑积极	野村大幅上调目标价 (三星 +225%、海力士 +255%) , 重估为 AI 基础设施资产	较上一报告期
AI 基建 / 电网	↑积极	高盛: 2030 数据中心电力需求 +170%; 电网成比芯片更硬瓶颈; CME 拟推 GPU 期货	较上一报告期
中资 AI 出海并购	↓消极	Manus 因监管令脱离 Meta, 预示中资 AI 技术并购审查收紧	本期新增覆盖

EN — Note on the table. Direction assessed on information flow within the coverage window, not share-price action; no market-price data entered today's source set. Per Chinese market convention, red denotes positive and green denotes negative. Comparisons reference our own archived issues of 2026-08-11 and earlier.

💡 投资结论（中英双语） / Investment Conclusion

- ▶ **结论一（算力与电力）**：大摩/高盛/野村一致看多 AI 基建链。资本开支上修（2026 美国大科技 \$8050 亿、2027/2028 全球五大 \$1.2 万/\$1.4 万亿）、电力需求 2030 +170%、存储进入 HBM 超级周期——**硬件（GPU、HBM、电力设备、电网）与推理云是最确定性受益环节**。
- ▶ **结论二（模型层分化）**：国产开源“集团军”压低闭源模型定价权，但 DeepSeek 逆势涨价显示头部厂商开始从“算力补贴”转向“平台/生态”变现。**路由层（OpenRouter 类）与 Agent 框架价值抬升**，单一模型厂商护城河收窄。
- ▶ **结论三（风险）**：算力金融化（GPU 期货、\$5000 亿资本平台）放大“循环融资”与债务风险；欧盟水印/透明度执法与中资出海并购审查，构成**合规与地缘双重约束**，需警惕估值在盈利上调周期见顶后的回撤。

EN — **Investment Conclusion.** (1) Compute & power: Morgan Stanley, Goldman and Nomura are aligned bullish on the AI-infrastructure chain — rising capex, +170% data-center power by 2030, and an HBM super-cycle make GPUs, HBM, power equipment and the grid the most defensive beneficiaries. (2) Model-layer divergence: China's open-source wave compresses closed-model pricing power, yet DeepSeek's price hikes signal a shift from compute subsidy to platform/ecosystem monetization; routing and agent frameworks gain value. (3) Risks: financialization of compute (GPU futures, \$500B vehicles) amplifies circular-financing and debt risk; EU watermark enforcement and Chinese outbound-M&A scrutiny add compliance and geopolitical constraints.

🔗 数据来源 / Sources (16 个)

展开 / 收起 全部来源

📊 数据来源：WebSearch 多源检索（AI 资讯聚合 + 官方博客/新闻稿 + 高盛/摩根士丹利/野村研报）· 每条均附原文链接

🕒 生成时间：2026-08-18（历史补生成） | 覆盖窗口：8月15日 00:00 ~ 24:00 北京时间 | 32 张卡片 / 16 个溯源来源

⚠️ 本报告仅供研究参考，不构成投资建议。所有资讯均保留原文链接可溯源；厂商自测数据与未发布模型结论已在正文标注。